Università degli Studi di Palermo
Dipartimento di Ingegneria — Laurea Magistrale in Ingegneria Informatica

Deep Learning-Based Early Detection of Alzheimer's Disease

From Speech in Single- and Multi-Language Settings

Candidato
Antonio Spedito

Relatore
Prof. S.M. Siniscalchi

Controrelatore
Prof. M. Morana

Correlatore
Dott. M. La Quatra

A.A. 2024–2025

Struttura

1. Contesto e Motivazione
2. Dataset e Obiettivi
3. Architettura del Sistema
4. Risultati Sperimentali
5. Conclusioni

Emergenza Alzheimer: Numeri e Costi

55M+

Pazienti nel 2019.

Raddoppio entro il 2050.

USD 1.3T

Costo sanitario globale annuo.

23%

Popolazione IT over-65.

Emergenza Alzheimer: Numeri e Costi

55M+

Pazienti nel 2019.

Raddoppio entro il 2050.

USD 1.3T

Costo sanitario globale annuo.

23%

Popolazione IT over-65.

Necessità di Strumenti Scalabili

- Diagnosi attuale: PET, puntura lombare, test MMSE (invasivi o soggettivi)
- MMSE: punteggio 0–30, soglia ≤ 24 per decadimento. Sensibile solo a stadi avanzati
- Obiettivo: rilevare la fase **prodromica (MCI)** prima dell'AD conclamato

Voce Rivela Declino Prima dei Test Classici

La produzione del parlato richiede una complessa coordinazione neuro-motoria, che si altera nelle primissime fasi del declino:

- **Semantico:** anomia, lessico impoverito
- **Sintattico:** semplificazione morfologica
- **Acustico:** pause anomale, tremori laringei

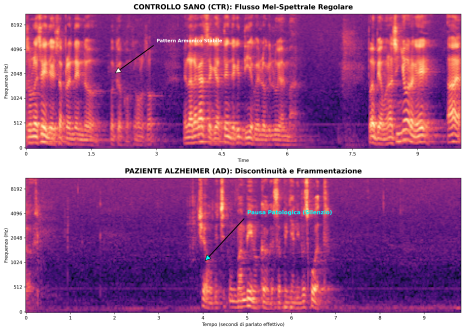

CTR (stabile) vs AD (frammentato, pause anomale).

Voce Rivela Declino Prima dei Test Classici

La produzione del parlato richiede una complessa coordinazione neuro-motoria, che si altera nelle primissime fasi del declino:

- **Semantico:** anomia, lessico impoverito
- **Sintattico:** semplificazione morfologica
- **Acustico:** pause anomale, tremori laringei

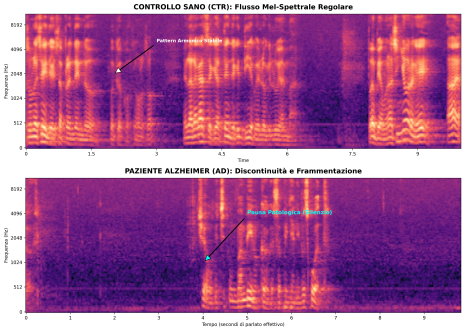

CTR (stabile) vs AD (frammentato, pause anomale).

Finestra di Screening

MCI (MMSE $\approx$ 27): rilevabile vocalmente **prima** della diagnosi clinica.

Obiettivi di Ricerca

1. **Cross-Lingual:** i biomarcatori vocali trasferiscono tra lingue diverse in **zero-shot**?

Obiettivi di Ricerca

1. **Cross-Lingual:** i biomarcatori vocali trasferiscono tra lingue diverse in **zero-shot**?
2. **Multimodale:** la fusione audio+testo supera i modelli unimodali in ambienti **clinici rumorosi**?

Obiettivi di Ricerca

1. **Cross-Lingual:** i biomarcatori vocali trasferiscono tra lingue diverse in **zero-shot**?
2. **Multimodale:** la fusione audio+testo supera i modelli unimodali in ambienti **clinici rumorosi**?
3. **ASR:** Parakeet (RNN-T) preserva le disfluenze che Whisper **cancella**?

Due Dataset: Benchmark Internazionale e Corpus Clinico

ADReSSo (EN)

- 174 soggetti (87 AD + 87 CN), test fisso (75)
- Rigorosamente **bilanciato** per età e genere
- Qualità da studio (Cookie Theft task)
- Utilizzo: benchmark SOTA e pre-training acustico

Due Dataset: Benchmark Internazionale e Corpus Clinico

ADReSSo (EN)

- 174 soggetti (87 AD + 87 CN), test fisso (75)
- Rigorosamente **bilanciato** per età e genere
- Qualità da studio (Cookie Theft task)
- Utilizzo: benchmark SOTA e pre-training acustico

SHAPE-AD (IT)

- 140 soggetti (51 CTR, 43 MCI, 46 Mild-AD)
- Bilanciamento diagnostico; forte rumore clinico
- Popolazione a basso grado di istruzione
- Centri: Palermo e Agrigento (+ Napoli validazione)
- Valutazione: **5-fold** CV stratificata

SHAPE-AD: Sette Task Vocali

Descrivi come faresti un panino con burro e marmellata.

si sa che erano troppo eccellenti i pezzi

le mie ragazze ci parevano giuste

i medici fanno gia' guarnire la veneziana perche' lampeggia

gli scalatori vogliono spegnere quaggiu' il fine vecchio tutte le volte che lampeggia

una giusta statua lascia mangiare uno smorfioso

T01–T02: Parlato Spontaneo

Produzione narrativa spontanea e procedurale (Cookie Theft, Sandwich).

Massimizzano la discriminazione cognitiva stressando memoria e pianificazione.

T03–T07: Lettura e Ripetizione

Ripetizione di frasi, lettura testo bilanciato, fluenza semantica e fonologica, richiamo differito.

Pipeline Unimodali

Prima della fusione, ogni modalità viene elaborata separatamente per estrarre rappresentazioni complementari.

Pipeline Acustica (Feature Tradizionali e Deep)

Estrazione di feature acustiche (eGeMAPS, Whisper Embeddings) e classificazione (XGBoost/LogReg).

Pipeline Unimodali

Prima della fusione, ogni modalità viene elaborata separatamente per estrarre rappresentazioni complementari.

Pipeline Acustica (Feature Tradizionali e Deep)

Estrazione di feature acustiche (eGeMAPS, Whisper Embeddings) e classificazione (XGBoost/LogReg).

Pipeline Testuale (Deep NLP)

Conversione in testo tramite ASR ed estrazione di embedding semantici tramite Transformer.

Parakeet Preserva Sintomi, Whisper Cancella

Encoder-Decoder (Whisper)

- LM interno: genera contesto futuro
- Allucinazione nei silenzi patologici
- Normalizza agrammatismi e neologismi

RNN-Transducer (Parakeet)

- Causale: nessun contesto futuro
- Emette solo con evidenza acustica
- **Preserva** disfluenze e parafasie

Parakeet Preserva Sintomi, Whisper Cancella

Encoder-Decoder (Whisper)

- LM interno: genera contesto futuro
- Allucinazione nei silenzi patologici
- Normalizza agrammatismi e neologismi

RNN-Transducer (Parakeet)

- Causale: nessun contesto futuro
- Emette solo con evidenza acustica
- **Preserva** disfluenze e parafasie

IT-0035 (MMSE 23 — Paragrammatismo):

Parakeet: ``Si troviamo in cucina... il maschetto è il bambino...''

Whisper: ``Ci troviamo in cucina... il maschietto e il bambino...''

Whisper corregge il paragrammatismo: il marcatore clinico sparisce.

ADReSSo: +2.81% sul Benchmark SOTA

Validiamo le pipeline sul benchmark internazionale ADReSSo (test fisso, 75 campioni).

Tipo	Modello	Acc (%)	F1	Sens	Spec
Baseline	Luz '21 Acustico	64.79	0.64	–	–
Baseline	Luz '21 Linguistico	78.87	0.79	–	–
Ref.	Pappagari '21 Acustico	71.80	0.72	0.72	–
Ref.	Pappagari '21 Ling.	84.51	0.85	0.84	–
Acustico	XGBoost + eGeMAPS	69.01	0.69	0.71	0.66
Acustico	XGBoost + Whisper Enc	78.87	0.79	0.71	0.86
Linguistico	BERT + Whisper v3	80.28	0.80	0.77	0.83
Linguistico	BERT + CrisperWhisper	84.51	0.84	0.77	**0.92**
Linguistico	BERT + Parakeet 1.1b	83.10	0.83	0.77	0.88
Linguistico	BERT + Parakeet 0.6b	**87.32**	**0.87**	**0.83**	**0.92**

+2.81% sul SOTA (Pappagari '21). Parakeet 0.6b domina su tutte le pipeline.

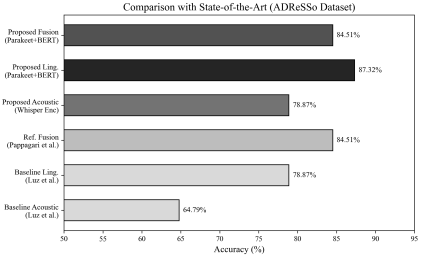

Architettura Multimodale Proposta

- **Wav2Vec 2.0 XLS-R**: tremori e prosodia patologica
- **UmBERTo / XLM-RoBERTa**: anomie e semplificazioni sintattiche
- **Cross-Attention bidirezionale**: allinea testo e audio
- **GMU**: pesa le modalità in base al rumore

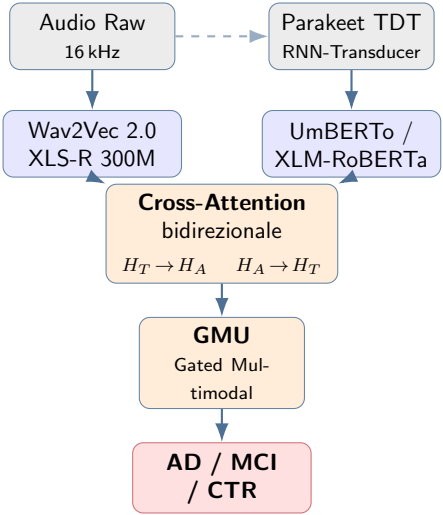

SHAPE-AD: Fusione Supera Modelli Unimodali

Sul dataset clinico italiano (rumore reale, bassa scolarità), il modello multimodale domina su tutti i singoli approcci unimodali.

Cat.	Modello	Acc	F1	Sens	Spec
Fusione	Multimodale (UmBERTo)	**0.81** ± **0.06**	**0.80** ± **0.07**	**0.94** ± **0.06**	0.68 ± 0.12
Fusione	Multimodale (BERT-IT)	0.71 ± 0.09	0.71 ± 0.09	0.63 ± 0.11	**0.79** ± **0.17**
Testuale	UmBERTo	0.71 ± 0.06	0.70 ± 0.07	0.65 ± 0.15	0.76 ± 0.14
Acustico	LogReg + Whisper	0.68 ± 0.07	0.68 ± 0.07	0.59 ± 0.12	0.76 ± 0.11
Acustico	XGBoost + Whisper	0.66 ± 0.06	0.65 ± 0.07	0.58 ± 0.12	0.73 ± 0.11
Acustico	LogReg + eGeMAPS	0.62 ± 0.09	0.62 ± 0.09	0.61 ± 0.16	0.63 ± 0.12

Fusione: +13pp Acc vs solo acustico. Valutazione: 5-fold CV stratificata.

SHAPE-AD: Fusione Supera Modelli Unimodali

Sul dataset clinico italiano (rumore reale, bassa scolarità), il modello multimodale domina su tutti i singoli approcci unimodali.

Cat.	Modello	Acc	F1	Sens	Spec
Fusione	Multimodale (UmBERTo)	**0.81** ± **0.06**	**0.80** ± **0.07**	**0.94** ± **0.06**	0.68 ± 0.12
Fusione	Multimodale (BERT-IT)	0.71 ± 0.09	0.71 ± 0.09	0.63 ± 0.11	**0.79** ± **0.17**
Testuale	UmBERTo	0.71 ± 0.06	0.70 ± 0.07	0.65 ± 0.15	0.76 ± 0.14
Acustico	LogReg + Whisper	0.68 ± 0.07	0.68 ± 0.07	0.59 ± 0.12	0.76 ± 0.11
Acustico	XGBoost + Whisper	0.66 ± 0.06	0.65 ± 0.07	0.58 ± 0.12	0.73 ± 0.11
Acustico	LogReg + eGeMAPS	0.62 ± 0.09	0.62 ± 0.09	0.61 ± 0.16	0.63 ± 0.12

Fusione: +13pp Acc vs solo acustico. Valutazione: 5-fold CV stratificata.

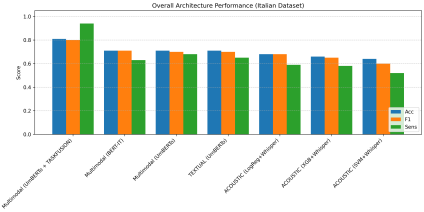

Task Narrativi Dominano Classificazione

Non tutti i task vocali sono ugualmente informativi. I task narrativi (T01, T02) stressano la memoria semantica e risultano i più discriminanti.

Task	Miglior Modello	Acc	F1	Sens	Spec
T01	UmBERTo	0.77 ± 0.04	0.77 ± 0.04	0.72 ± 0.05	0.82 ± 0.07
T02	Multimodale UmBERTo	**0.79 ± 0.11**	**0.79 ± 0.11**	0.74 ± 0.14	**0.84 ± 0.19**
T03	Multimodale UmBERTo	0.71 ± 0.03	0.70 ± 0.03	0.66 ± 0.17	0.77 ± 0.17
T04	SVM + Whisper	0.76 ± 0.05	0.76 ± 0.05	**0.75 ± 0.09**	0.76 ± 0.05
T05	UmBERTo	0.71 ± 0.10	0.70 ± 0.10	0.57 ± 0.17	0.84 ± 0.12
T06	LogReg + eGeMAPS	0.73 ± 0.07	0.73 ± 0.07	**0.75 ± 0.05**	0.70 ± 0.09
T07	SVM + Whisper	0.72 ± 0.12	0.72 ± 0.12	0.73 ± 0.09	0.71 ± 0.22

T01 e T02 (parlato spontaneo) dominano: massimo stress su memoria semantica e pianificazione.

Task Narrativi Dominano Classificazione

Non tutti i task vocali sono ugualmente informativi. I task narrativi (T01, T02) stressano la memoria semantica e risultano i più discriminanti.

Task	Miglior Modello	Acc	F1	Sens	Spec
T01	UmBERTo	0.77 ± 0.04	0.77 ± 0.04	0.72 ± 0.05	0.82 ± 0.07
T02	Multimodale UmBERTo	**0.79 ± 0.11**	**0.79 ± 0.11**	0.74 ± 0.14	**0.84 ± 0.19**
T03	Multimodale UmBERTo	0.71 ± 0.03	0.70 ± 0.03	0.66 ± 0.17	0.77 ± 0.17
T04	SVM + Whisper	0.76 ± 0.05	0.76 ± 0.05	**0.75 ± 0.09**	0.76 ± 0.05
T05	UmBERTo	0.71 ± 0.10	0.70 ± 0.10	0.57 ± 0.17	0.84 ± 0.12
T06	LogReg + eGeMAPS	0.73 ± 0.07	0.73 ± 0.07	**0.75 ± 0.05**	0.70 ± 0.09
T07	SVM + Whisper	0.72 ± 0.12	0.72 ± 0.12	0.73 ± 0.09	0.71 ± 0.22

T01 e T02 (parlato spontaneo) dominano: massimo stress su memoria semantica e pianificazione.

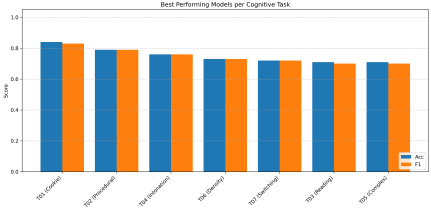

OR Triage: Priorità alla Sensibilità

In uno screening di primo livello il costo di un falso negativo (paziente non rilevato) è molto maggiore di un falso positivo. La logica OR massimizza la sensibilità.

Logica Disgiuntiva

- Allerta se $P > 0.5$ in **almeno uno** tra T01, T02
- Falso negativo $=$ paziente non rilevato
- Spec. 71%: accettabile in pre-screening non invasivo

OR Triage: Priorità alla Sensibilità

In uno screening di primo livello il costo di un falso negativo (paziente non rilevato) è molto maggiore di un falso positivo. La logica OR massimizza la sensibilità.

Logica Disgiuntiva

- Allerta se $P > 0.5$ in **almeno uno** tra T01, T02
- Falso negativo = paziente non rilevato
- Spec. 71%: accettabile in pre-screening non invasivo

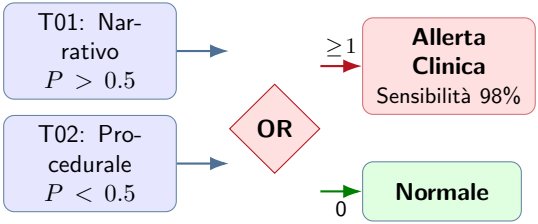

Strategie di Aggregazione: OR Voting Domina

Ogni paziente esegue più task vocali. Predizioni aggregate sui task T01 e T02 (fusione dei due task narrativi).

Strategia	Acc	F1	Sens	Spec
Soft Voting	0.80 ± 0.12	0.80 ± 0.12	0.80 ± 0.10	0.80 ± 0.19
Hard Voting	0.79 ± 0.11	0.78 ± 0.11	0.67 ± 0.16	**0.90 ± 0.12**
Max Confidence	0.81 ± 0.11	0.81 ± 0.11	0.82 ± 0.13	0.81 ± 0.18
Patient OR	**0.84 ± 0.04**	**0.83 ± 0.04**	**0.98 ± 0.04**	0.71 ± 0.06

Strategie di Aggregazione: OR Voting Domina

Ogni paziente esegue più task vocali. Predizioni aggregate sui task T01 e T02 (fusione dei due task narrativi).

Strategia	Acc	F1	Sens	Spec
Soft Voting	0.80 ± 0.12	0.80 ± 0.12	0.80 ± 0.10	0.80 ± 0.19
Hard Voting	0.79 ± 0.11	0.78 ± 0.11	0.67 ± 0.16	**0.90 ± 0.12**
Max Confidence	0.81 ± 0.11	0.81 ± 0.11	0.82 ± 0.13	0.81 ± 0.18
Patient OR	**0.84 ± 0.04**	**0.83 ± 0.04**	**0.98 ± 0.04**	0.71 ± 0.06

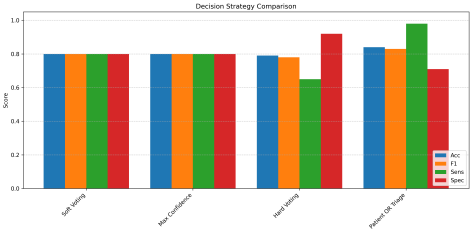

Sistema Regge sui Casi Difficili: Impaired vs CTR

Il test più stringente: distinguere la fase prodromica (MCI + Mild-AD) dai controlli sani, dove anche i clinici faticano.

- **Impaired** = MCI + Mild-AD vs CTR (MMSE $\approx$ 27)
- Al limite dei test neuropsicologici classici
- Zero fine-tuning specifico: valutazione in zero-shot

Metodo	Acc	F1	Sens	Spec
OR Voting	**0.80** $\pm$ **0.13**	**0.79** $\pm$ **0.15**	**0.94** $\pm$ **0.10**	0.68 $\pm$ 0.24
Meta-Clf (XGB)	0.79 $\pm$ 0.12	0.78 $\pm$ 0.14	0.76 $\pm$ 0.24	**0.82** $\pm$ **0.29**
Soft Voting	0.78 $\pm$ 0.12	0.78 $\pm$ 0.12	0.74 $\pm$ 0.12	**0.82** $\pm$ **0.19**

Sistema Regge sui Casi Difficili: Impaired vs CTR

Il test più stringente: distinguere la fase prodromica (MCI + Mild-AD) dai controlli sani, dove anche i clinici faticano.

- **Impaired** = MCI + Mild-AD vs CTR (MMSE $\approx$ 27)
- Al limite dei test neuropsicologici classici
- Zero fine-tuning specifico: valutazione in zero-shot

Metodo	Acc	F1	Sens	Spec
OR Voting	**0.80** $\pm$ **0.13**	**0.79** $\pm$ **0.15**	**0.94** $\pm$ **0.10**	0.68 $\pm$ 0.24
Meta-Clf (XGB)	0.79 $\pm$ 0.12	0.78 $\pm$ 0.14	0.76 $\pm$ 0.24	**0.82** $\pm$ **0.29**
Soft Voting	0.78 $\pm$ 0.12	0.78 $\pm$ 0.12	0.74 $\pm$ 0.12	**0.82** $\pm$ **0.19**

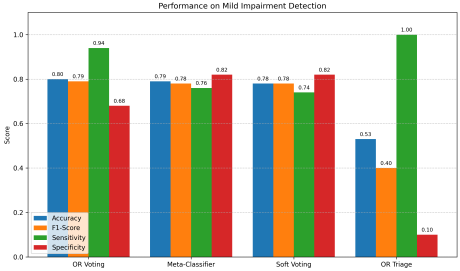

Validazione Esterna: Zero-Shot su Napoli

Il modello, allenato solo su dati di Palermo e Agrigento, viene testato sui pazienti del centro di Napoli senza alcun riallenamento.

AD vs CTR (40 sogg.: 22 AD + 18 CTR)

Strategia	Acc	F1	Sens	Spec
Mean Voting	0.68	0.67	0.64	0.72
OR Voting	**0.78**	**0.76**	**0.91**	0.61
AND Voting	0.62	0.62	0.50	**0.78**

Pazienti esterni di Napoli valutati interamente in **zero-shot** (modello mai allenato su di loro).

Validazione Esterna: Zero-Shot su Napoli

Il modello, allenato solo su dati di Palermo e Agrigento, viene testato sui pazienti del centro di Napoli senza alcun riallenamento.

AD vs CTR (40 sogg.: 22 AD + 18 CTR)

Strategia	Acc	F1	Sens	Spec
Mean Voting	0.68	0.67	0.64	0.72
OR Voting	**0.78**	**0.76**	**0.91**	0.61
AND Voting	0.62	0.62	0.50	**0.78**

Pazienti esterni di Napoli valutati interamente in **zero-shot** (modello mai allenato su di loro).

Screening: Impaired vs CTR (71 sogg.)

Strategia	Acc	F1	Sens	Spec
Mean Voting	0.59	0.57	0.55	**0.72**
OR Voting	**0.72**	**0.66**	**0.75**	0.61

Impaired = MCI + Mild-AD. OR Voting bilancia **Acc** e **Sens** anche fuori dal dominio di training.

Regressione MMSE: Zero-Shot Supera Training Nativo

Oltre alla classificazione, il modello predice il punteggio MMSE continuo (0–30) come proxy della severità cognitiva.

Modello	Train→Test	RMSE	MAE
Pappagari '21	EN→EN	3.85	–
XLM-RoBERTa	EN→EN	4.53	3.48
XLM-RoBERTa	EN→IT **Zero-Shot**	**1.92**	**1.43**
XLM-RoBERTa	IT→IT	2.18	1.82
UmBERTo	IT→IT	2.26	1.92

Regressione MMSE: Zero-Shot Supera Training Nativo

Oltre alla classificazione, il modello predice il punteggio MMSE continuo (0–30) come proxy della severità cognitiva.

Modello	Train→Test	RMSE	MAE
Pappagari '21	EN→EN	3.85	–
XLM-RoBERTa	EN→EN	4.53	3.48
XLM-RoBERTa	EN→IT **Zero-Shot**	**1.92**	**1.43**
XLM-RoBERTa	IT→IT	2.18	1.82
UmBERTo	IT→IT	2.26	1.92

EN→IT Zero-Shot (RMSE **1.92**) supera EN→EN nativo (4.53): i marcatori di severità **trasferiscono**.

Nota: basso RMSE IT dovuto a $\sigma_{\text{MMSE}} \approx 1.0$ vs EN $\sigma \approx 5.5$.

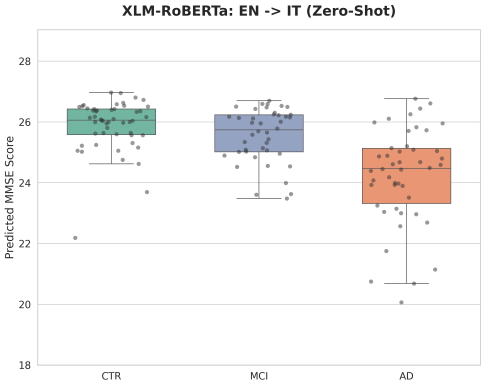

Biomarcatori Vocali Trasferiscono tra Lingue

Il modello italiano classifica pazienti inglesi **senza riallenamento**.

Direzione	Tipo	Acc	F1	Sens	Spec
EN→EN	Ref.	**0.87**	**0.87**	0.83	**0.92**
IT→IT	Ref.	0.81	0.80	**0.94**	0.68
IT→EN	Zero-Shot	0.79	0.79	0.77	0.81
EN→IT	Zero-Shot	0.74	0.73	0.54	**0.92**
Mixed→EN	Training	0.79	0.79	0.74	0.83
Mixed→IT	Training	0.75	0.75	0.78	0.73

IT→EN: 79%

a 5.5pt da Pappagari '21 (84.51%, supervisionato).

- Distanza coseno cross-lingua < 0.05: rappresentazioni EN e IT sovrapposte
- PCA: direzioni malattia parallele, spazio latente cattura tratti cognitivi

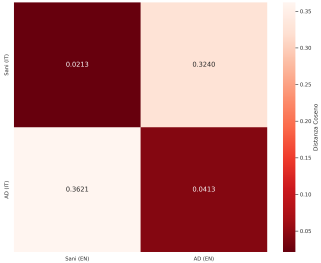

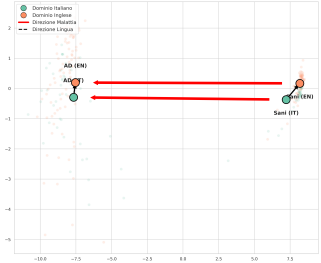

Conclusioni e Prospettive

- Transfer cross-lingua zero-shot: **79% Acc**
  IT→EN, a 5.5pt dal supervisionato

Conclusioni e Prospettive

- Transfer cross-lingua zero-shot: **79% Acc** IT→EN, a 5.5pt dal supervisionato
- Fusione multimodale: **84% Acc** con OR Triage (+13pp rispetto al solo canale acustico)

Conclusioni e Prospettive

- Transfer cross-lingua zero-shot: **79% Acc** IT→EN, a 5.5pt dal supervisionato
- Fusione multimodale: **84% Acc** con OR Triage (+13pp rispetto al solo canale acustico)
- Parakeet preserva disfluenze patologiche che Whisper elimina sistematicamente

Conclusioni e Prospettive

- Transfer cross-lingua zero-shot: **79% Acc** IT→EN, a 5.5pt dal supervisionato
- Fusione multimodale: **84% Acc** con OR Triage (+13pp rispetto al solo canale acustico)
- Parakeet preserva disfluenze patologiche che Whisper elimina sistematicamente
- OR Triage: **98%** sensibilità su SHAPE-AD, **91%** su validazione esterna Napoli

Limiti

- Dataset clinico di **140 soggetti**: dimensione ridotta per architetture deep, limita la generalizzazione

Prospettive Future

- Estensione multi-centro del corpus
- Integrazione modulo handwriting (trimodale)
- App mobile per screening vocale di primo livello

Grazie per l'attenzione.